

Olympic Analytics Platform

End-to-End Data Analytics & Machine Learning Project

Author: Girandoux Fandio

Technologien: PostgreSQL • SQL • Python • Machine Learning • Power BI • Streamlit

Zeitraum: Olympische Spiele 1904–2016

1. Executive Summary

Die Olympic Analytics Platform ist ein vollständiges End-to-End Data-Analytics-Projekt zur Analyse historischer Olympischer Spieldaten.

Ziel des Projekts ist die Entwicklung einer zentralen Analyseplattform, die Datenaufbereitung, Datenmodellierung, Business Intelligence, Machine Learning und interaktive Web-Dashboards miteinander verbindet.

Das Projekt umfasst:

- Datenbereinigung und Transformation
- Aufbau einer PostgreSQL-Datenbank
- Entwicklung analytischer SQL-Abfragen
- Erstellung eines Power BI Dashboards
- Entwicklung eines Machine-Learning-Modells
- Bereitstellung einer Streamlit-Webanwendung

Die Plattform ermöglicht sowohl historische Analysen als auch Vorhersagen zukünftiger Medaillenchancen.

2. Business Problem

Olympische Daten enthalten große Mengen historischer Informationen über:

- Athleten
- Länder
- Sportarten
- Medaillen
- Geschlechterverteilung
- Leistungsentwicklung

Ohne geeignete Datenanalyse sind langfristige Trends und Erfolgsfaktoren nur schwer erkennbar.

Ziel dieses Projekts ist die Entwicklung einer datengetriebenen Plattform zur Beantwortung strategischer Fragestellungen rund um olympische Leistungen.

3. Projektziele

Die Hauptziele des Projekts sind:

Datenanalyse

- Analyse olympischer Leistungsdaten
- Identifikation langfristiger Trends
- Vergleich von Ländern und Sportarten

Business Intelligence

- Entwicklung interaktiver Dashboards
- Bereitstellung entscheidungsrelevanter Kennzahlen

Machine Learning

- Vorhersage von Medaillengewinnen
 - Analyse relevanter Einflussfaktoren
 - Zukunftssimulation olympischer Ergebnisse
-

4. Research Questions

Das Projekt beantwortet folgende zentrale Fragestellungen:

Länderanalyse

- Welche Länder dominieren die Olympischen Spiele?
- Welche Nationen zeigen langfristiges Wachstum?

Sportanalyse

- Welche Sportarten gewinnen an Bedeutung?
- Welche Disziplinen liefern die meisten Medaillen?

Athletenanalyse

- Wie verändern sich Alter, Größe und Gewicht über die Zeit?
- Welche Athleten gehören zu den erfolgreichsten Olympioniken?

Gender & Diversity

- Wie entwickelt sich die Beteiligung von Frauen?
- Wie verändert sich die Medaillenverteilung zwischen den Geschlechtern?

Machine Learning

- Welche Faktoren beeinflussen die Wahrscheinlichkeit eines Medaillengewinns?
- Welche Länder besitzen zukünftig die größten Erfolgschancen?

5. Data Engineering

Datenquelle

Historische Olympische Spieldaten von:

- Athleten
- Ländern
- Sportarten
- Wettbewerben
- Medaillen

Zeitraum:

1904 – 2016

Datenbereinigung

Durchgeführt mit Python und Pandas:

- Entfernung von Duplikaten
 - Behandlung fehlender Werte
 - Standardisierung von Länder- und Sportnamen
 - Datentyp-Korrekturen
-

Datenmodellierung

Zur Optimierung analytischer Abfragen wurde ein Star-Schema entwickelt.

Dimensionstabellen

- dim_athletes
- dim_countries
- dim_date
- dim_events
- dim_medals
- dim_sports

Faktentabelle

- fact_participations
-

6. SQL Database

Datenbanksystem

PostgreSQL

Implementierung

Schema-Erstellung

- Datenbankstruktur
- Beziehungen
- Primär- und Fremdschlüssel

Datenimport

Import aller CSV-Dateien in PostgreSQL

Datenvalidierung

Überprüfung von:

- Null-Werten
- Duplikaten
- Referenzieller Integrität

Analytische SQL-Abfragen

Beispiele:

- Top-Länder nach Medaillen
- Medaillenentwicklung über die Zeit
- Geschlechterverteilung
- Sportarten-Rankings

7. Power BI Dashboard

Das Power BI Dashboard wurde für Business Intelligence und Datenvisualisierung entwickelt.

Dashboard-Seiten

Executive Overview

Überblick über:

- Athleten
- Länder
- Sportarten
- Olympische Beteiligungen

Country Performance Analysis

Analyse von:

- Länder-Rankings
- Medaillenentwicklungen
- Erfolgreichen Sportarten

Athlete Performance Analysis

Analyse von:

- Alter
- Gewicht
- Größe
- BMI

Gender & Diversity Analysis

Analyse von:

- Männer- und Frauenanteilen
- Medaillenverteilungen
- langfristigen Entwicklungen

Historical Trends Analysis

Langfristige Entwicklung von:

- Beteiligungen
- Medaillen
- Länderleistungen

Project Insights & Conclusions

Zusammenfassung der wichtigsten Erkenntnisse.

8. Machine Learning

Ziel

Vorhersage zukünftiger Medaillengewinne.

Verwendetes Modell

Random Forest Classifier

Gründe:

- hohe Genauigkeit
 - robuste Ergebnisse
 - Interpretierbarkeit
-

Verwendete Features

- Alter
 - Größe
 - Gewicht
 - BMI
 - Geschlecht
 - Sportart
 - Land
 - Olympiajahr
-

Modellauswertung

Bewertungsmetriken:

- Accuracy
 - Classification Report
 - Confusion Matrix
 - Feature Importance
-

Zukunftsprognosen

Simulation zukünftiger Olympischer Spiele:

- 2028
- 2032
- 2036

Ergebnis:

Schätzung der Medaillenwahrscheinlichkeiten für Athleten und Länder.

9. Streamlit Application

Zur Bereitstellung der Analysen wurde eine interaktive Streamlit-Webanwendung entwickelt.

Enthaltene Seiten

- Executive Overview
 - Country Performance
 - Athlete Performance
 - Gender Analysis
 - Historical Trends
 - Medal Prediction
 - Project Insights
-

Funktionen

- Interaktive Filter
 - Echtzeit-Analysen
 - Dynamische Visualisierungen
 - Machine-Learning-Demo
-

10. Key Findings

Die wichtigsten Erkenntnisse des Projekts:

Länder

- Die USA gehören zu den erfolgreichsten Olympianationen.
- Einige Länder zeigen langfristig starkes Wachstum.

Geschlechterentwicklung

- Der Anteil weiblicher Athleten ist kontinuierlich gestiegen.
- Die Geschlechterverteilung nähert sich zunehmend an.

Sportarten

- Bestimmte Sportarten dominieren die Medaillenvergabe.
- Einige Disziplinen gewinnen über die Jahrzehnte an Bedeutung.

Machine Learning

Die wichtigsten Einflussfaktoren auf Medaillengewinne sind:

- Sportart
- Herkunftsland
- Alter
- Körperliche Merkmale

11. Technologien

Bereich	Technologie
Datenanalyse	Python
Datenverarbeitung	Pandas
Datenbank	PostgreSQL
SQL	PostgreSQL , SQL
Visualisierung	Power BI
Machine Learning	Scikit-Learn
Web App	Streamlit
Versionskontrolle	Git & GitHub

12. Conclusion

Die Olympic Analytics Platform demonstriert einen vollständigen Data-Analytics-Lebenszyklus:

- Datenaufbereitung
- Datenmodellierung
- Datenbankentwicklung
- SQL-Analysen
- Business Intelligence
- Machine Learning
- Web-Deployment

Das Projekt zeigt die praktische Anwendung moderner Data-Science- und Analytics-Technologien innerhalb einer realistischen End-to-End-Lösung und eignet sich hervorragend als Portfolio-Projekt für Positionen im Bereich Data Analyst, Business Intelligence Analyst, Data Scientist oder Data Engineer.