

Olympic Analytics Platform

Technische Dokumentation

Version

1.0

Autor

Girandoux Fandio

Projekttyp

End-to-End Data Analytics & Machine Learning Projekt

Technologien

- PostgreSQL
 - SQL
 - Power BI
 - Python
 - Pandas
 - Scikit-Learn
 - Streamlit
 - GitHub
-

1. Projektübersicht

Die Olympic Analytics Platform ist ein End-to-End Data-Analytics-Projekt zur Analyse historischer Olympischer Spiele von 1904 bis 2016.

Das Projekt vereint den kompletten Datenanalyseprozess:

- Datenaufbereitung
- Datenmodellierung
- Datenbankentwicklung
- SQL-Analysen
- Business Intelligence
- Machine Learning
- Interaktive Web-Anwendung

Ziel des Projekts ist die Umwandlung historischer olympischer Rohdaten in aussagekräftige Analysen, Dashboards und Prognosemodelle.

2. Systemarchitektur

Datenfluss des Projekts:

- ➔ Rohdaten
 - ➔ Datenbereinigung
 - ➔ Datenmodellierung
 - ➔ PostgreSQL Datenbank
 - ➔ SQL Analysen
 - ➔ Power BI Dashboard
 - ➔ Machine Learning Modell
 - ➔ Streamlit Anwendung
-

3. Datenquelle

Verwendeter Datensatz:

Historische Olympische Spiele

Zeitraum:

1904 – 2016

Enthaltene Informationen:

- Athleten
- Länder
- Sportarten
- Wettbewerbe
- Medaillen
- Geschlecht
- Alter
- Körpergröße
- Gewicht

Verwendete Dateien:

- olympics.csv
 - olympics_BI_cleaned.csv
 - olympics_ML_cleaned.csv
-

4. Datenaufbereitung

Zur Sicherstellung einer hohen Datenqualität wurden mehrere Schritte durchgeführt.

Datenbereinigung

- Entfernung von Duplikaten
- Behandlung fehlender Werte
- Vereinheitlichung von Datentypen
- Berechnung zusätzlicher Merkmale

Feature Engineering

Erstellte Merkmale:

- BMI (Body Mass Index)
 - Medal Win Indicator
 - Teilnahmekennzahlen
 - Altersgruppen
-

5. Datenbankdesign

Datenbanksystem

PostgreSQL

Datenmodell

Star Schema

Dimensionstabellen

- dim_athletes
- dim_countries
- dim_sports
- dim_events
- dim_medals
- dim_date

Faktentabelle

- fact_participations
-

6. Entity Relationship Diagram (ERD)

Das relationale Datenmodell basiert auf einer zentralen Faktentabelle.

Beziehungen:

fact_participations

- athlete_id → dim_athletes
- country_id → dim_countries
- sport_id → dim_sports
- event_id → dim_events
- medal_id → dim_medals
- date_id → dim_date

Referenz:

ERD_Model.png

7. SQL-Entwicklung

Verwendete SQL-Dateien

01_schema_creation.sql

Erstellt das Datenbankschema.

02_table_creation.sql

Erstellt alle Tabellen.

03_csv_import.sql

Importiert die CSV-Dateien.

04_data_validation.sql

Überprüft die Datenqualität.

05_analytics_queries.sql

Enthält analytische SQL-Abfragen.

8. SQL-Analysen

Folgende Analysen wurden durchgeführt:

- Erfolgreichste Länder
 - Medaillenentwicklung über die Zeit
 - Sportarten mit den meisten Medaillen
 - Geschlechterverteilung
 - Altersentwicklung von Athleten
 - Länder-Sport-Kombinationen
 - Teilnahmeentwicklung
-

9. Power BI Dashboard

Das Dashboard besteht aus sechs Analysebereichen.

1. Executive Overview

KPIs:

- Total Athletes
- Total Countries
- Total Participations
- Total Sports

Visualisierungen:

- Medals Over Time
 - Top Countries
 - Sport Distribution
 - Participation Growth
-

2. Country Performance Analysis

KPIs:

- Country Medals
- Total Medals
- Total Sports
- Leading Country
-

Visualisierungen:

- Country Medal Ranking
- Country Dominance Timeline
- Country-Sport Heatmap

3. Athlete Performance Analysis

KPIs:

- Average Age
- Average Height
- Average Weight
- Average BMI

Visualisierungen:

- Top Athletes
 - Height vs Weight
 - Athlete Age Analysis
 - Sport Comparison
-

4. Gender & Diversity Analysis

KPIs:

- Total Athletes
- Male Athletes
- Female Athletes
- Female Participation Rate

Visualisierungen:

- Medal Distribution by Gender
 - Participation by Gender
 - Age Distribution
 - Gender Trends
-

5. Historical Trends Analysis

KPIs:

- First Olympic Year
- Latest Olympic Year
- Years Covered
- Total Medals

Visualisierungen:

- Medal Growth
- Participation Growth
- Country Evolution
- Historical Trends

6. Project Insights & Conclusions

Zusammenfassung der wichtigsten Projektergebnisse und Erkenntnisse.

10. Power BI Datenmodell

Power BI verwendet das relationale Star Schema der PostgreSQL-Datenbank.

Referenz:

Data_Model.png

Eigenschaften:

- Faktentabelle
 - Dimensionstabellen
 - One-to-Many Beziehungen
 - Zentrale Filterlogik
-

11. Machine Learning

Zielsetzung

Vorhersage der Wahrscheinlichkeit eines Medaillengewinns.

Modell

Random Forest Classifier

Zielvariable

medal_win

Werte:

- 1 = Medaille gewonnen
 - 0 = Keine Medaille
-

Verwendete Merkmale

- age
- height_cm
- weight_kg
- bmi
- gender
- sport_name

- country_name
 - year
-

Trainingsprozess

Trainingsdaten:

80 %

Testdaten:

20 %

Methode:

Stratifizierte Aufteilung

12. Modellbewertung

Verwendete Kennzahlen:

- Accuracy
- Precision
- Recall
- F1 Score
- Confusion Matrix

Erzeugte Dateien:

- model_metrics.csv
 - confusion_matrix.png
 - feature_importance.png
-

13. Zukunftsprognosen

Simulation zukünftiger Olympischer Spiele:

- 2028
- 2032
- 2036

Ausgabedatei:

future_olympic_predictions.csv

Ziel:

Schätzung zukünftiger Medaillenwahrscheinlichkeiten.

14. Streamlit Anwendung

Hauptdatei

app.py

Seiten

- Executive Overview
- Country Performance
- Athlete Performance
- Gender Analysis
- Historical Trends
- Medal Prediction
- Project Insights

Funktionen

- Interaktive Filter
- KPI-Dashboards
- Dynamische Visualisierungen
- Machine Learning Demo
- Projektzusammenfassung

15. Projektstruktur

Das Projekt wurde modular aufgebaut.

Hauptbereiche:

- Daten
- SQL Datenbank
- Power BI
- Machine Learning
- Streamlit
- Dokumentation

Dadurch wird eine einfache Wartung und Erweiterung ermöglicht.

16. Projektergebnisse

Wesentliche Erkenntnisse:

- Die USA gehören zu den erfolgreichsten Olympianationen.

- Die Frauenbeteiligung ist langfristig deutlich gestiegen.
 - Bestimmte Sportarten dominieren die Medaillenverteilung.
 - Alter, Sportart und Herkunftsland beeinflussen die Wahrscheinlichkeit eines Medaillengewinns.
-

17. Einschränkungen

- Historische Daten nur bis 2016
 - Zukunftsprognosen basieren auf Wahrscheinlichkeiten
 - Keine Echtzeitdaten
 - Keine individuellen Athletenprognosen
-

18. Zukünftige Erweiterungen

Mögliche Weiterentwicklungen:

- Echtzeit-Datenintegration
 - Erweiterte Vorhersagemodelle
-

19. Fazit

Die Olympic Analytics Platform demonstriert einen vollständigen modernen Data-Analytics-Workflow.

Das Projekt verbindet Data Engineering, SQL, Business Intelligence, Machine Learning und Web-Entwicklung in einer integrierten Analyseplattform.

Es zeigt praxisnah die Fähigkeiten eines Data Analysts, BI Developers und angehenden Data Scientists über den gesamten Datenlebenszyklus hinweg.